



RIESGO CREDITICIO: DE LOS DATOS A LA DECISION

CCANA ROMERO JEISON KEVIN

EL PROBLEMA

CADA APROBACIÓN DE CRÉDITO ES UNA APUESTA BAJO INCERTIDUMBRE

- APROBAR DE MÁS → PÉRDIDAS POR IMPAGO QUE NO SE RECUPERAN POR COMPLETO
- RECHAZAR DE MÁS → SE PIERDE NEGOCIO RENTABLE CON CLIENTES QUE SÍ HABRÍAN PAGADO
- LA PREGUNTA QUE RESOLVEMOS: ¿A QUIÉN APROBAR, Y CON QUÉ EVIDENCIA?

LOS DATOS

Give Me Some Credit

Improve on the state of the art in credit scoring by predicting the probability that somebody will experience financial distress in the next two years.

150,000

solicitantes de crédito

10

variables de comportamiento crediticio

6.7%


tasa de impago severo (2 años) — cartera desbalanceada

VARIABLE OBJETIVO: **SERIOUSDLQIN2YRS** — IMPAGO DE 90+ DÍAS EN LOS SIGUIENTES 2 AÑOS.

	SeriousDlqin2yrs	RevolvingUtilizationOfUnsecuredLines	age	NumberOfTime30-59DaysPastDueNotWorse	DebtRatio	MonthlyIncome	NumberOfOpenCreditLinesAndLoans	NumberOfTimes90DaysLate	NumberRealEstateLoansOrLines	NumberOfTime60-89DaysPastDueNotWorse	NumberOfDependents
count	150000.000000	150000.000000	150000.000000	150000.000000	150000.000000	1.202690e+05	150000.000000	150000.000000	150000.000000	150000.000000	146076.000000

METODOLOGÍA

DE LA EXPLORACIÓN A LA DECISIÓN: 5 ETAPAS



P1 — HALLAZGOS DEL EDA

- LOS CÓDIGOS "96/98" EN VARIABLES DE ATRASO NO SON CEROS DE BAJO RIESGO: ESAS FILAS TIENEN 54.6% DE IMPAGO REAL, 8× LA TASA BASE
- DEBTRATIO SE DISTORSIONA CUANDO EL INGRESO REPORTADO ES CASI NULO — HAY QUE TRATARLO CON CUIDADO, NO TOMARLO LITERAL
- EL INGRESO Y EL PATRIMONIO NO SON LOS MEJORES PREDICTORES — EL COMPORTAMIENTO DE PAGO RECIENTE SÍ

```
late_cols = [  
    'NumberOfTime30-59DaysPastDueNotWorse',  
    'NumberOfTimes90DaysLate',  
    'NumberOfTime60-89DaysPastDueNotWorse',  
]  
error_code_mask = (df[late_cols] >= 96).any(axis=1)  
print('Filas con código de error 96/98:', error_code_mask.sum())  
print('Tasa de impago en filas con código de error:', df.loc[error_code_mask, TARGET_COL].mean())  
print('Tasa de impago global:', df[TARGET_COL].mean())
```

Filas con código de error 96/98: 269
Tasa de impago en filas con código de error: 0.5464684014869888
Tasa de impago global: 0.06684

```
print('age == 0:', (df['age'] == 0).sum())  
print('RevolvingUtilizationOfUnsecuredLines > 1:', (df['RevolvingUtilizationOfUnsecuredLines'] > 1).sum(),  
      '| max:', df['RevolvingUtilizationOfUnsecuredLines'].max())  
print('DebtRatio > 1:', (df['DebtRatio'] > 1).sum(),  
      f"({(df['DebtRatio'] > 1).mean():.1%})",  
      '| max:', df['DebtRatio'].max())
```

age == 0: 1
RevolvingUtilizationOfUnsecuredLines > 1: 3321 | max: 50708.0
DebtRatio > 1: 35137 (23.4%) | max: 329664.0

```
df.groupby(TARGET_COL).mean(numeric_only=True)
```

Python

	RevolvingUtilizationOfUnsecuredLines	age	NumberOfTime30-59DaysPastDueNotWorse	DebtRatio	MonthlyIncome	NumberOfOpenCreditLinesAndLoans	NumberOfTimes90DaysLate	NumberRealEstateLoansOrLines	NumberOfTime60-89DaysPastDueNotWorse	NumberOfDependents
SeriousDlqin2yrs										
0	6.168855	52.751375	0.280109	357.151168	6747.837774	8.493620	0.135225	1.020368	0.126666	0.743417
1	4.367282	45.926591	2.388490	295.121066	5630.826493	7.882306	2.091362	0.988530	1.828047	0.948208

P2 — SEGMENTACIÓN DE RIESGO

CUATRO PERFILES DE CLIENTE, UN SEGMENTO CRÍTICO

- ALTO RIESGO: 5% DE LA CARTERA, 45% DE IMPAGO (JÓVENES, ALTA UTILIZACIÓN, ATRASOS ACTIVOS)
- DOS SEGMENTOS DE BAJO RIESGO CON PERFILES ECONÓMICOS OPUESTOS (ALTO PATRIMONIO VS. PERFIL MODESTO)
- UN SEGMENTO CON DEBTRATIO EXTREMO PERO BAJO RIESGO REAL — LA VARIABLE ENGAÑA SI SE USA SOLA



```
segment_profile = df.groupby('cluster').agg(
    n=('cluster', 'size'),
    pct_total=('cluster', lambda s: len(s) / len(df) * 100),
    tasa_impago=(TARGET_COL, 'mean'),
    edad_prom=('age', 'mean'),
    utilizacion_prom=('RevolvingUtilizationOfUnsecuredLines', 'mean'),
    debratio_prom=('DebtRatio', 'mean'),
    ingreso_prom=('MonthlyIncome', 'mean'),
    atraso90_prom=('NumberOfTimes90DaysLate', 'mean'),
    lineas_abiertas_prom=('NumberOfOpenCreditLinesAndLoans', 'mean'),
    inmuebles_prom=('NumberRealEstateLoansOrLines', 'mean'),
).round(2).sort_values('tasa_impago', ascending=False)

segment_profile
```

	n	pct_total	tasa_impago	edad_prom	utilizacion_prom	debratio_prom	ingreso_prom	atraso90_prom	lineas_abiertas_prom	inmuebles_prom
cluster										
1	7654	5.10	0.45	45.65	0.79	197.81	5315.56	1.32	6.82	0.72
3	48753	32.50	0.05	50.27	0.30	27.66	8829.04	0.02	12.09	1.78
0	81519	54.35	0.04	53.83	0.30	99.77	5273.65	0.03	6.20	0.49
2	12074	8.05	0.04	54.34	0.27	3021.96	5113.33	0.02	10.02	1.70

```
def nombrar_segmento(row):
    if row['tasa_impago'] > 0.20:
        return 'Alto riesgo'
    if row['debratio_prom'] > 500:
        return 'Bajo riesgo (DebtRatio anómalo)'
    if row['ingreso_prom'] > 7000:
        return 'Bajo riesgo (patrimonio alto)'
    return 'Bajo riesgo (perfil modesto)'


segment_profile['nombre'] = segment_profile.apply(nombrar_segmento, axis=1)
cluster_to_nombre = segment_profile['nombre'].to_dict()
df['segmento'] = df['cluster'].map(cluster_to_nombre)

segment_profile
```

	n	pct_total	tasa_impago	edad_prom	utilizacion_prom	debratio_prom	ingreso_prom	atraso90_prom	lineas_abiertas_prom	inmuebles_prom	nombre
cluster											
1	7654	5.10	0.45	45.65	0.79	197.81	5315.56	1.32	6.82	0.72	Alto riesgo
3	48753	32.50	0.05	50.27	0.30	27.66	8829.04	0.02	12.09	1.78	Bajo riesgo (patrimonio alto)
0	81519	54.35	0.04	53.83	0.30	99.77	5273.65	0.03	6.20	0.49	Bajo riesgo (perfil modesto)
2	12074	8.05	0.04	54.34	0.27	3021.96	5113.33	0.02	10.02	1.70	Bajo riesgo (DebtRatio anómalo)

PREDICTIVO

PAGADORES



0.869

AUC — LightGBM (modelo final)


0.580

Estadístico KS

MEJORA MODESTA SOBRE LA REGRESIÓN LOGÍSTICA (AUC 0.862)
— CASI TODA LA SEÑAL ES CAPTURABLE CON UN MODELO LINEAL,
MÁS SIMPLE DE EXPLICAR.

P4 — POLÍTICA DE APROBACIÓN

DE LA PROBABILIDAD A LA DECISIÓN DE NEGOCIO



- SUPUESTOS: TASA 18%, LGD 60%, MONTO US\$ 10,000
- APROBAR CON PD < 23% (~55% DE LA CARTERA) MAXIMIZA LA UTILIDAD ESPERADA
- DEJA SOLO ~1% DE IMPAGO EN LA CARTERA APROBADA — MUY POR DEBAJO DEL LÍMITE DE RIESGO (5%)

P4 — SENSIBILIDAD

LA TASA DE INTERÉS PESA MÁS QUE AFINAR EL MODELO

- SUBIR LA TASA A 24% CASI DUPLICA LA UTILIDAD ESPERADA (US\$ 18.3M VS. US\$ 11.5M)
- UN LGD MÁS ALTO (80%, MENOR RECUPERO) REDUCE TANTO LA APROBACIÓN ÓPTIMA COMO LA UTILIDAD
- LA DECISIÓN DE PRECIO ES UNA PALANCA DE NEGOCIO MÁS POTENTE QUE EL AJUSTE FINO DEL SCORE

```
scenarios = [
    ('Base', RATE, LGD),
    ('LGD alto (recupero menor)', RATE, 0.80),
    ('Tasa alta', 0.24, LGD),
    ('Tasa baja', 0.12, LGD),
]

sens_rows = []
for name, rate_s, lgd_s in scenarios:
    be_s = rate_s / (rate_s + lgd_s)
    util_s = (1 - pd_hat) * rate_s * LOAN_AMOUNT - pd_hat * lgd_s * LOAN_AMOUNT
    approved_s = pd_hat < be_s
    sens_rows.append({
        'escenario': name,
        'tasa': rate_s,
        'lgd': lgd_s,
        'umbral_be': round(be_s, 4),
        'tasa_aprobacion': round(approved_s.mean(), 3),
        'tasa_impago_aprobados': round(y_test[approved_s].mean(), 4),
        'utilidad_total': round(util_s[approved_s].sum(), 0),
    })

pd.DataFrame(sens_rows)
```

	escenario	tasa	lgd	umbral_be	tasa_aprobacion	tasa_impago_aprobados	utilidad_total
0	Base	0.18	0.6	0.2308	0.536	0.0097	11481802.0
1	LGD alto (recupero menor)	0.18	0.8	0.1837	0.463	0.0084	9218552.0
2	Tasa alta	0.24	0.6	0.2857	0.598	0.0115	18274468.0
3	Tasa baja	0.12	0.6	0.1667	0.431	0.0072	5539972.0

P5 — TABLERO



- KPIS, SEGMENTACIÓN, DESEMPEÑO DEL MODELO Y POLÍTICA DE APROBACIÓN EN UN SOLO LUGAR
- GRÁFICOS INTERACTIVOS CON TOOLTIP Y TABLA DE RESPALDO PARA CADA UNO

RECOMENDACIÓN

Aprobar solicitudes con probabilidad de impago menor a **23%** genera una utilidad esperada de **~US\$ 511 por solicitante**, con solo **~1% de riesgo real** en la cartera aprobada — muy por debajo del límite de riesgo de referencia (5%), que hoy no resulta vinculante.

GRACIAS